



Instituto Tecnológico y de Estudios Superiores de Monterrey

Maestría en Inteligencia Artificial Aplicada

Proyecto Integrador

Aplicación de modelos de aprendizaje supervisado para el cálculo de
probabilidad de pérdida de empleo en clientes de nómina

Avance 4. Modelos alternativos

Grupo 10:

Abraham Cabanzo Jiménez - A01795355

Kevin Alejandro Ayón Payán - A01740679

Pedro Ulises Meléndez Ortega - A00716301

Doctora: Grettel Barceló Alonso

16 de febrero de 2025

Introducción

A lo largo del proyecto se han realizado distintas estrategias de limpieza y mejoramiento de los datos para maximizar la eficiencia en el momento de implementar análisis que se lleven a cabo en un entorno de la vida real, además de una investigación e implementación inicial de modelos que podrían utilizarse para resolver la problemática establecida por el equipo. En este avance, se realizará una serie de desarrollos de diversos modelos con el fin de encontrar el de mejor desempeño/rendimiento que pueda resolver el problema con los mejores resultados posibles.

En este nuevo avance, se enlistan todos los modelos alternativos que el equipo construyó, con la finalidad de elaborar una comparación de dichos modelos con base a métricas que nos distingan su rendimiento y desempeño al utilizar los datos.

A lo largo de todo este avance se abordará un ligero proceso de comparación, ajuste y selección con el fin de terminar 2 modelos candidatos, para poder ajustarlos y seleccionarlos para tener un modelo individual final.

Preguntas a contestar

Modelos a utilizar

Debido a que el dataset está desbalanceado 96% y 4% respectivamente, la Precisión no es el mejor indicador para evaluar su desempeño.

Se realizó una asignación diferenciada de pesos en las clases en la etapa de entrenamiento mediante la función ClassWeight para otorgar más peso a la clase minoritaria.

La precisión no es la mejor métrica para evaluar el comportamiento de los modelos dado el desbalance, por lo que se utilizaron las siguientes métricas de desempeño

Comparación de modelos

Se ejecutaron **8 modelos**, 4 considerando las variables originales y 4 más, usando PCA e inicialmente, con información de 2023.

Sin PCA

Utilizando componentes principales (PCA)	RECALL	AUC-ROC	PR-AUC	ACCURACY	Descripción de resultados
Regresión logística	.7474	.7635	.1585	.6472	→ Para el modelo de regresión logística, la métrica Recall logra un desempeño más que aceptable de 0.74, lo que hace ser un modelo muy capaz de identificar correctamente a las personas que pronto serán despedidas. → Además, cuenta con un AUC-ROC considerablemente alto de 0.76, lo que representa que el modelo puede distinguir correctamente entre personas con riesgo y los que no (lo que en términos generales, todos los modelos tienen esta métrica decente). → No obstante, la regresión logística tiene un PR-AUC muy reducido, siendo uno de los más bajos en comparación a los demás modelos de 0.15, lo que indica que genera bastante variedad de falsos positivos, lo que en otras palabras se refiere a que el modelo marca clientes como riesgosos cuando en realidad no lo son, lo que puede perjudicar el negocio. → Por último, tenemos un Accuracy en la

					regresión logística de 0.64 lo que, si bien puede parecer relativamente alta, en realidad es algo baja, por lo que es necesario realizar una comparación de esta métrica con otros modelos para ver en general qué se espera. Conclusión general del modelo: Siendo uno de los modelos más simples, tiene una baja precisión en los casos positivos y genera muchos falsos, lo que provocaría bastantes errores y problemas en el área de negocio.
Bosque Aleatorio	.1094	.7972	0.3005	.9605	→ Para el modelo de bosque aleatorio, la métrica Recall tiene un desempeño bastante bajo de 0.10, lo que indica que prácticamente no está detectando a los clientes que tienen riesgo a ser despedidos. → Adicionalmente, cuenta con un AUC-ROC considerablemente alto de 0.79, lo que representa que el modelo puede distinguir eficientemente entre personas con riesgo y los que no (lo que en términos generales, todos los modelos tienen esta métrica decente). → Además, el bosque aleatorio logra una mejoría en la métrica PR-AUC, pero considerablemente baja con 0.30, lo que indica que genera bastante variedad de falsos positivos, pero con un mejor nivel de acierto. → Por último, tenemos un Accuracy en el bosque aleatorio más alta que cualquier otro modelo, con un total de 0.96. Este alto valor indica un desempeño bastante aceptable, pero será necesario seguir la comparación con los demás modelos para establecer criterios de desempeño. Conclusión general del modelo: Este modelo cuenta con un accuracy bastante elevado, pero no se debe guiarse solamente por eso. Este modelo presenta otras fallas bastante notorias como el bajo recall, lo que provoca ser un modelo que no detecta correctamente a los clientes riesgosos
Redes neuronal MLP	.7307	.8094	.2541	.7380	→ Para el modelo de redes neuronales, la métrica Recall tiene un desempeño bastante aceptable de 0.73, lo que indica que el modelo tiene un desempeño aceptable en la precisión de distinguir correctamente la proporción de clientes en riesgo. → Además, cuenta con un AUC-ROC

					considerablemente alto de 0.80, siendo el más alto en comparación a los demás modelos, por lo que el modelo puede distinguir eficientemente entre personas con riesgo y los que no (lo que en términos generales, todos los modelos tienen esta métrica decente). → Para la métrica PR-AUC, si bien tiene mejor desempeño en comparación a otros modelos (0.25), tiene una gran ventana de mejora para tener un mejor rendimiento general del modelo. → Por último, tenemos un Accuracy en en redes neuronales decente con un total de 0.73. Este alto valor indica un desempeño bastante aceptable, pero será necesario seguir la comparación con los demás modelos para establecer criterios de desempeño. Conclusión general del modelo: Este modelo en términos generales presenta un buen desempeño, con gran ventana de mejora en métricas como PR-AUC. Este modelo puede ser considerado como un rendimiento equilibrado y que puede mejorar.
XGBOOST	.7587	.8061	.2480	.7024	→ Para el modelo de XGBOOST, la métrica Recall tiene un desempeño bastante aceptable de 0.75, lo que es bastante parecido el desempeño en comparación con otros modelos, lo que indica ser aceptable. → Además, cuenta con un AUC-ROC considerablemente alto de 0.80, es bastante elevado para distinguir eficientemente entre personas con riesgo y los que no (lo que en términos generales, todos los modelos tienen esta métrica decente). → Para la métrica PR-AUC, si bien tiene mejor desempeño en comparación a otros modelos (0.24), al igual que redes neuronales tiene una gran ventana de mejoría para esta métrica. → Por último, tenemos un Accuracy de 0.70, lo que es bastante elevado en comparación a otros modelos. Conclusión general del modelo: Este modelo en términos generales presenta un buen desempeño, con rendimiento bastante similar a redes neuronales, con la diferencia de que este presenta un mejor recall, aunque un accuracy más bajo.
Light GBM	.7791	.7968	.2231	.6652	→ Para el modelo de Light GBM, la

					métrica Recall tiene un desempeño bastante mejor que los demás de 0.78, siendo el más elevado en comparación de los demás modelos. → Además, cuenta con un AUC-ROC considerablemente alto de 0.79, es bastante elevado para distinguir eficientemente entre personas con riesgo y los que no (lo que en términos generales, todos los modelos tienen esta métrica decente). → Para la métrica PR-AUC, tiene un total de 0.22, lo cual es más bajo el rendimiento con respecto a otros modelos, será importante revisar si puede realizarse mejoras para evitar errores en los resultados. → Por último, tenemos un Accuracy de 0.66, lo que es un rendimiento equilibrado, que puede mejorar pero tampoco es el peor. Conclusión general del modelo: Este modelo en términos generales presenta un buen desempeño, con su recall bastante elevado puede ser uno de los mejores modelos a implementar, aunque tiene algunas ventanas de mejora que el equipo tendría que revisar mejorar para tener los mejores resultados.
--	--	--	--	--	---

Conclusión y selección final del modelo

Existen 3 modelos con un desempeño bastante aceptable y equilibrado en comparación al total, que son LightGBM, XGBoost y Redes neuronales. Estos 3 modelos, si bien cuentan con un desempeño parecido en métricas generales, tienen diferencias en métricas bastante importantes como Recall o Accuracy, por lo que basándonos en los resultados de Recall, y en el rendimiento de las demás métricas, se optó por elegir los modelos **LightGBM** y **XGBoost**.

Con PCA

Utilizando componentes principales (PCA)	RECALL	AUC-ROC	PR-AUC	ACCURACY	Descripción de resultados
Regresión logística	.8686	.9184	.3061	.8350	→ Para el modelo de regresión logística, la métrica Recall logra un desempeño más que aceptable de 0.86, lo que hace ser un modelo muy capaz de identificar

					correctamente a las personas que pronto serán despedidas. → Además, cuenta con un AUC-ROC bastante alto de 0.91, lo que representa que el modelo puede distinguir correctamente entre personas con riesgo y los que no (lo que en términos generales, todos los modelos tienen esta métrica decente). → No obstante, la regresión logística tiene un PR-AUC muy reducido, siendo uno de los más bajos en comparación a los demás modelos de 0.30, lo que indica que genera bastante variedad de falsos positivos, lo que en otras palabras se refiere a que el modelo marca clientes como riesgosos cuando en realidad no lo son, lo que puede perjudicar el negocio. → Por último, tenemos un Accuracy en la regresión logística de 0.83 lo que es alta e indica un desempeño alto para el modelo de regresión logística. Conclusión general del modelo: Siendo uno de los modelos más simples, tiene resultados bastante satisfactorios, aunque con algunas ventanas de oportunidad como PR-AUC, que se requiere establecer mejoras para que no perjudique los resultados del modelo.
Bosque Aleatorio	0.1724	0.8267	0.3840	0.9629	→ Para el modelo de bosque aleatorio, la métrica Recall tiene un desempeño bastante bajo de 0.17, lo que indica que prácticamente no está detectando a los clientes que tienen riesgo a ser despedidos. → Adicionalmente, cuenta con un AUC-ROC considerablemente alto de 0.82, lo que representa que el modelo puede distinguir eficientemente entre personas con riesgo y los que no (lo que en términos generales, todos los modelos tienen esta métrica decente). → Además, el bosque aleatorio logra una mejoría en la métrica PR-AUC, pero considerablemente baja con 0.38, lo que indica que genera bastante variedad de falsos positivos, pero con un mejor nivel de acierto. → Por último, tenemos un Accuracy en el bosque aleatorio más alta que cualquier otro modelo, con un total de 0.96. Este alto valor indica un desempeño bastante aceptable, pero será necesario seguir la comparación con los demás modelos para establecer criterios de desempeño.

					Conclusión general del modelo: Este modelo cuenta con un accuracy bastante elevado, pero no se debe guiarse solamente por eso. Este modelo presenta otras fallas bastante notorias como el bajo recall, lo que provoca ser un modelo que no detecta correctamente a los clientes riesgosos
Redes neuronal MLP	.9301	.9499	.5198	.8421	→ Para el modelo de redes neuronales, la métrica Recall tiene un desempeño bastante alto de 0.93, lo que indica que el modelo tiene un desempeño bastante correcto en la precisión de distinguir correctamente la proporción de clientes en riesgo. → Además, cuenta con un AUC-ROC considerablemente alto de 0.95, siendo el más alto en comparación a los demás modelos, por lo que el modelo puede distinguir eficientemente entre personas con riesgo y los que no (lo que en términos generales, todos los modelos tienen esta métrica decente). → Para la métrica PR-AUC, tiene el mayor desempeño en comparación a los demás modelos con un total de 0.52, lo cual es considerado aceptable pero que puede mejorar. → Por último, tenemos un Accuracy en en redes neuronales decente con un total de 0.84. Este alto valor indica un desempeño bastante aceptable, pero será necesario seguir la comparación con los demás modelos para establecer criterios de desempeño. Conclusión general del modelo: Este modelo en términos generales presenta muy buenos resultados en sus métricas, teniendo un desempeño bastante aceptable para implementar en el proyecto.
XGBOOST	.8485	.9160	.4535	.8418	→ Para el modelo de XGBOOST, la métrica Recall tiene un desempeño bastante aceptable de 0.84, lo que es bastante parecido el desempeño en comparación con otros modelos, lo que indica ser aceptable. → Además, cuenta con un AUC-ROC considerablemente alto de 0.91, es bastante elevado para distinguir eficientemente entre personas con riesgo y los que no (lo que en términos generales, todos los modelos tienen esta métrica decente). → Para la métrica PR-AUC, si bien tiene mejor desempeño en comparación a

					otros modelos (0.45), al igual que redes neuronales tiene una gran ventana de mejoría para esta métrica. → Por último, tenemos un Accuracy de 0.84, lo que es bastante elevado en comparación a otros modelos. Conclusión general del modelo: Este modelo en términos generales presenta un buen desempeño al igual que redes neuronales, por lo que podría ser bastante eficiente al implementar en este proyecto.
Light GBM	.8103	.8715	.3705	.7772	→ Para el modelo de Light GBM, la métrica Recall tiene un desempeño elevado de 0.81, pero no siendo de los mejores, aunque sigue siendo bastante aceptable. → Además, cuenta con un AUC-ROC considerablemente alto de 0.87, es bastante elevado para distinguir eficientemente entre personas con riesgo y los que no (lo que en términos generales, todos los modelos tienen esta métrica decente). → Para la métrica PR-AUC, tiene un total de 0.37, lo cual es más bajo el rendimiento con respecto a otros modelos, será importante revisar si puede realizarse mejoras para evitar errores en los resultados. → Por último, tenemos un Accuracy de 0.77, lo que es un rendimiento equilibrado, que puede mejorar pero tampoco es el peor. Conclusión general del modelo: Este modelo en términos generales presenta un buen desempeño, tiene recall bastante aceptable pero un accuracy que puede mejorar.

Conclusión y selección final del modelo

Existen 3 modelos con un desempeño bastante aceptable y equilibrado en comparación al total, que son Regresión logística, XGBoost y Redes neuronales. Estos 3 modelos, si bien cuentan con un desempeño parecido en métricas generales, tienen diferencias en métricas bastante importantes como Recall o Accuracy, por lo que basándonos en los resultados de Recall, y en el rendimiento de las demás métricas, se optó por elegir los modelos **Redes neuronales** y **XGBoost**.

Con estos resultados, también observamos que un modelo que debemos evitar en la medida de lo posible es el modelo de bosque aleatorio, pues presenta métricas bastante malas que en este área de negocio no es aceptable de ninguna manera.

Redes neuronales, en términos generales, fue el que mayor desempeño tuvo. No obstante, XGBoost también plantea un rendimiento bastante satisfactorio, lo que los mantiene como los dos mejores modelos para implementar en este proyecto.

En resumen, y considerando el modelo XGBoost, dado que **el objetivo principal es maximizar el recall**, los resultados muestran una diferencia clara entre usar PCA y no usarlo.

Métrica	Con PCA	Sin PCA	Diferencia
Accuracy	0.7025	0.8418	0.1393
Recall	0.7588	0.8486	0.0898
ROC-AUC	0.8062	0.916	0.1098
PR-AUC	0.2481	0.4535	0.2054